

Introduction to Machine learnings

* programming : input + equations = output Ex: $y = 3x^2$

* Machine learning: input + output = Equation

Exs

حال لونا معايا عدد من المأكولات بالساحة
لديها السعر - سب المأكولات ونقطاً و
أعرف لو ظهرت سنة جديدة أخرى سعرها
عناب 3 مرات "محاضرة" سبع
عناب 3 مرات "سكن" خصم في أعمال السنة
ناءاً على 1 dataset

60 Final

25 mid

15 Lab

input output

Size Price

90 ✓

input

100 ✓

input

ML Algorithms

Equation (Model)

105 ✓

output

أحياناً يطلب أن تقرراً طبقاً لـ input

↑
Data Set

- Row = training sample (example)
- m = Number of rows (training samples)

ML Algorithms

- 1) Supervised learning
 - 2) Unsupervised learning
 - 3) Reinforcement learning
- Content ✓

Supervised Learning

- Datasets: input + output
- Regression
- Classification

Unsupervised Learning

- Datasets: input only
- Clustering

* Regressions

* output (Continuous Values)

Exs

Size	Price
90	1H
100	1.2M

1000,000 : 2000,000

Range

* Classifications

* output (Discrete Values)

Exs 0, 1, 2, ...

	x	y	
1	1	1	1 (yes)
1	1	0	0 (No)
1	0	1	
0	0	0	

* Clustering: Divide dataset to groups

✓ → group A

• → group B

• ادخل حاجة معروفة قبل كل جماعات

أقرب لـ "A" جماعات

x	✓
✓	✓
✓	✓
✓	✓

* linear Regression with One Variable

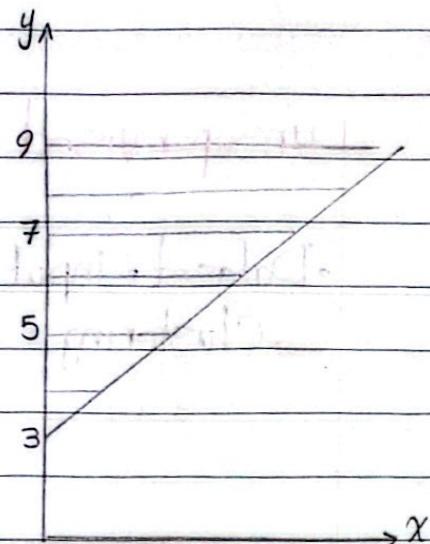
↓ ↓ ↓
 Dataset (i/p + o/p)
 ↓
 Continuous

Straight line
Equation

i/p actual output

x	y
0	3
1	5
2	7
3	9

$$y = mx + b$$



Model Representation:

Dataset

↓
ML Algorithm

[Linear regression
with one variable]

$$h = \varphi_0 + \varphi_1 x$$

unknowns: φ_0, φ_1

$x^{i/P} \rightarrow$ Equation \rightarrow predicted output
 h (hypothesis Function)

II linear regression with one Variable:

↓
 supervised
 input + output
 ↓
 continuous

↓
 one input
 one Feature

input	output	actual output

learning Algorithm
 linear regression
 with one variable

x → Equation
 (Model)

\rightarrow predicted output
 $h \rightarrow h$ (hypothesis)

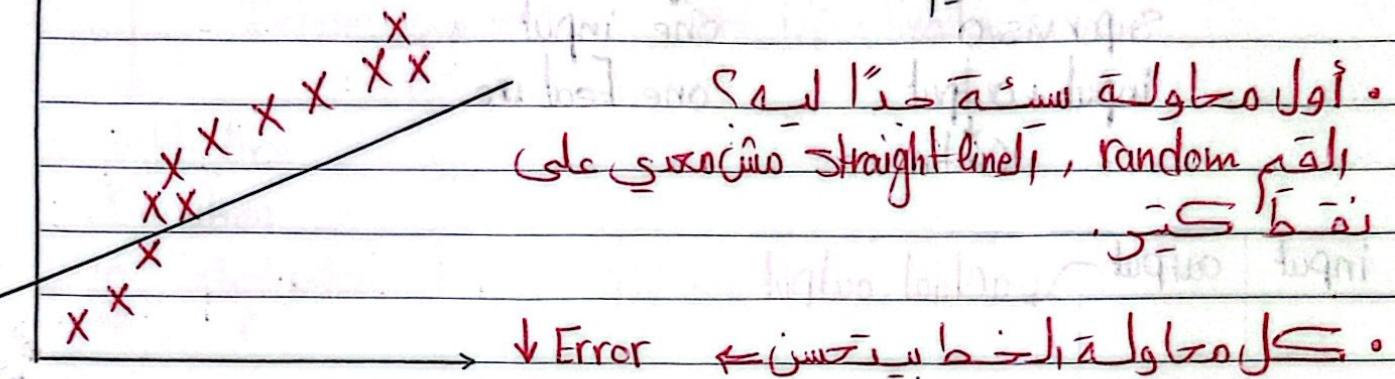
From straight line equation

$$\begin{aligned}
 & y = mx + b \\
 & y = b_0 + m_1 x \\
 & \downarrow \quad \downarrow \quad \downarrow \\
 & h = \theta_0 + \theta_1 x
 \end{aligned}$$

θ_0, θ_1 , unknowns

$$h = \theta_0 + \theta_1 x$$

Random $\leftarrow \theta_0, \theta_1$ لـ $y = \theta_0 + \theta_1 x$



Error Equation (Cost Function) MSE

$$J = \frac{1}{2m} \sum_{\text{predicted}, \text{actual}} (h - y)^2$$

Target & Minimize J
minimize $h \rightarrow h = \theta_0 + \theta_1 x$
minimize θ_0, θ_1

Gradient descent algorithm:

$$\theta_{\text{new}} = \theta_{\text{old}} - \alpha \frac{\partial J}{\partial \theta}$$

$$\theta_{0,\text{new}} = \theta_{0,\text{old}} - \alpha \frac{\partial J}{\partial \theta_0}$$

القوس

$$\frac{\partial J}{\partial \theta_0} = \frac{2}{2m} \sum_{(h-y)}^1 (1) (x - y)$$

نهايات القوس

$$\theta_{1,\text{new}} = \theta_{1,\text{old}} - \alpha \frac{\partial J}{\partial \theta_1}$$

$$\frac{\partial J}{\partial \theta_1} = \frac{2}{2m} \sum_{(h-y)}^1 (x - y)$$

نهايات القوس

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum (h - y)$$

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum (h - y) x$$

$$\theta_{0,\text{new}} = \theta_{0,\text{old}} - \alpha \frac{1}{m} \sum (h - y)$$

$$\theta_{1,\text{new}} = \theta_{1,\text{old}} - \alpha \frac{1}{m} \sum (h - y) x$$

Example 8

Consider the following training data for linear regression you're using linear regression and assume

$$\theta_0 = 2, \theta_1 = 2 \text{ and } \alpha = 0.1$$

x	y
2	3
3	4
4	5

- Compute the total error and update the values of θ_0, θ_1 after the first iteration.

First iteration:

$$\theta_0 = 2, \theta_1 = 2$$

$$J = \frac{1}{2m} \sum (h - y)^2$$

$$\theta_0 = \theta_0 - \frac{\alpha}{m} \sum (h - y)$$

$$\theta_1 = \theta_1 - \frac{\alpha}{m} \sum (h - y)x$$

$$\begin{aligned} h &= \theta_0 + \theta_1 x \\ h &= 2 + 2x \end{aligned}$$

x	y	h	(h-y)	(h-y)x	(h-y) ²
2	3	6	3	6	9
3	4	8	4	12	16
4	5	10	5	20	25
Σ		12	38	50	

$$J = \frac{1}{2m} \sum (h - y)^2 = \frac{1}{6} (50) = 8.3 \quad J = 8.3 \quad \#$$

$$\theta_0 = \theta_0 - \frac{\alpha}{m} \sum (h - y)$$

$$\theta_0 = 2 - \frac{0.1}{3} (12) = 1.6$$

$$\theta_0 = 1.6 \quad \#$$

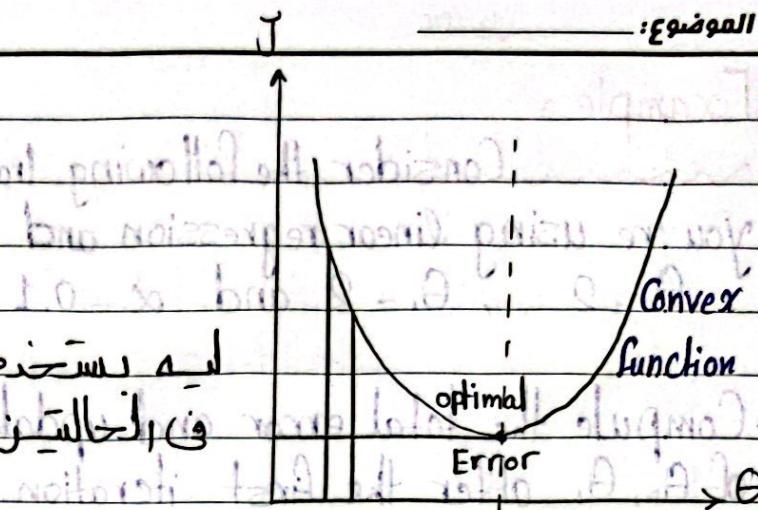
$$\theta_1 = \theta_1 - \frac{\alpha}{m} \sum (h - y)x$$

$$\theta_1 = 2 - \frac{0.1}{3} (38) = 0.73$$

$$\theta_1 = 0.73 \quad \#$$

$$\bullet J = \frac{1}{2m} \sum (h - y)^2$$

$$\cdot \theta_{\text{new}} = \theta_{\text{old}} - \alpha \frac{\partial J}{\partial \theta}$$



$$\theta \uparrow \rightarrow J \downarrow$$

$$\frac{\partial J}{\partial \theta} (+ve)$$

$$\theta_{\text{new}} = \theta_{\text{old}} - \alpha \nabla J$$

$$\theta_{old} = -ve$$

$$\theta_{\text{new}} = \theta_{\text{old}} - \alpha \Delta J$$

$$\theta \text{ sin} \theta - \text{cos} \theta < 0$$

بالأعلى J-θnew

* linear Regression with multiple Variables

Regression: Contains input & output

Multiple Variable : Multiple Features (x_1, x_2, \dots)

linear: linear function → High processing function

Dataset with multiple features

لتحتبر نفس معادلات الـ Variable features لـ θ حسب عدد n وكدة كدة θ ناتة

$$\theta_0 \rightarrow \theta_1$$

↳ Features number

with one Variable

$$\bullet h = \theta_0 + \theta_1 x$$

$$\cdot j = \frac{1}{2m} \sum (h - y)^2$$

$$\cdot \theta_0 = \theta_0 - \frac{\alpha}{m} \sum (h - y)$$

$$\cdot \theta_1 = \theta_1 - \frac{\alpha}{m} \sum (h - y)x$$

multiple gi Variablen LS Liθ, by Gradient Decent

with multiple Variables

$$h = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

$$\cdot J = \frac{1}{2m} \sum (h - y)^2$$

$$\Theta_0 = \Theta_0 - \frac{\alpha}{m} \sum (h - y)$$

$$\theta_1 = \theta_1 - \frac{\alpha}{m} \sum (h - y)x_1$$

$$\Theta_2 = \Theta_2 - \frac{\alpha}{m} \sum (h - y) x_2$$

$$\cdot \hat{\theta}_n = \theta_n - \frac{\alpha}{m} \sum (h - y) x_n$$

*feature scaling

① Mean - normalization

② Min-Max scaling

لوعندی $x_1, x_2 \leftarrow$ features لبيان مفهوم الواقع

لـ x قيمها متحدة أو مـ x كـ x أو

$$x_1: 0 \rightarrow 5 \quad \text{lim}$$

$$X_2: 100 \rightarrow 30000$$

مختاد أو متعارض

not - mated

1 Mean - normalization:

$$x' = \frac{x - \mu}{\max - \min}$$

الـ x أـحوـلـهـاـ إـلـىـ عـلـيـةـ

وأقصى مقدار المعلم أعلى وأقل قيمة \rightarrow min, max

new α → after scaling; H → average → $\frac{\mu_1 + \mu_2}{2}$
→ $\frac{\mu_1 + \mu_2}{2}$

② Min-Max Scaling

$$x' = \frac{x - \text{min}}{\text{max} - \text{min}}$$

CH_3Cl + O_2 \rightarrow CO_2 + H_2O

$$c(b-d) \leq \frac{s}{m} - \theta = \theta.$$

$$\lim_{n \rightarrow \infty} x_n = 0$$

Ex: Given dataset, Apply feature scaling using \rightarrow Mean-normalization
 \rightarrow Min-Max Scaling

	x_1	x_2	y
	200	2.2	✓
	160	1.9	✓
	180	2.1	✓
	240	2	✓

Solution

• Mean-normalization

↳ after

$$\hat{x} = \frac{x - \mu}{\max - \min}$$

	\hat{x}_1	\hat{x}_2	y
	0.0625	0.5	
	0.4375	-0.5	
	-0.1875	0.17	
	0.5625	-0.17	

$$\mu_1 = \frac{200 + 160 + 180 + 240}{4} = 195 \leftarrow \text{تحويل جملة إلى مصطلح}\ \text{متوسط}\ \text{أو}\ \mu$$

$$\mu_2 = \frac{2.2 + 1.9 + 2.1 + 2}{4} = 2.05$$

$$\hat{x}_1 = \frac{x_1 - 195}{240 - 160} \rightarrow \hat{x}_1 = \frac{x_1 - 195}{80} \leftarrow \text{تحويل جملة إلى مصطلح}\ \text{نسبة}\ \text{أو}\ \frac{\Delta x}{x_{\text{أقصى}} - x_{\text{أدنى}}}$$

$$\hat{x}_2 = \frac{x_2 - 2.05}{2.2 - 1.9} \rightarrow \hat{x}_2 = \frac{x_2 - 2.05}{0.3} \leftarrow \text{تحويل جملة إلى مصطلح}\ \text{نسبة}\ \text{أو}\ \frac{\Delta x}{x_{\text{أقصى}} - x_{\text{أدنى}}}$$

• Min-Max scaling

↳ after

$$\hat{x} = \frac{x - \min}{\max - \min}$$

	\hat{x}_1	\hat{x}_2	y
	0.5	1	
	0	0	
	0.25	0.66	
	1	0.33	

$$\hat{x}_1 = \frac{x_1 - 160}{240 - 160} \rightarrow \hat{x}_1 = \frac{x_1 - 160}{80}$$

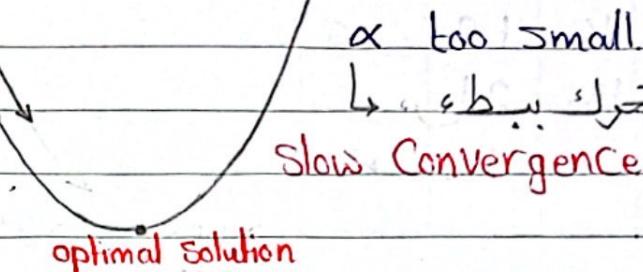
$$\hat{x}_2 = \frac{x_2 - 1.9}{2.2 - 1.9} \rightarrow \hat{x}_2 = \frac{x_2 - 1.9}{0.3}$$

* learning rate: (α) → given

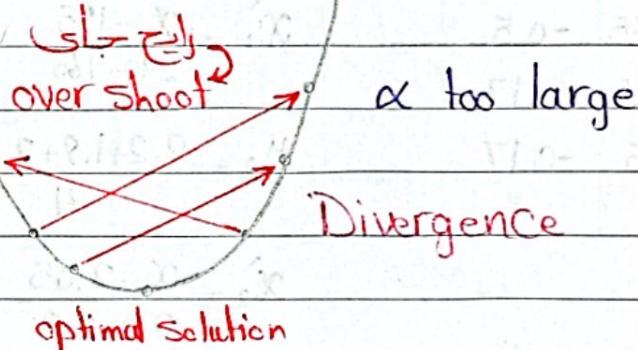
إيه تأثر α هي معدل التعلم
يعني إن الموديل يتبعي هستلم بسرعة
(zero range) ولابطء (النهاية من 1)

هنا لو α ← هتتحل ببطء
Convergence ← الموصول لنقطة الحل
هيكون بطيء جداً slow
ودى حاجة متشاءمة XXX

$$\theta_{\text{new}} = \theta_{\text{old}} - \alpha \frac{\partial J}{\partial \theta}$$



هنا زي الموسنة لأنهم راجحة جاية
ومن عارفين نوصل لنقطة الحل
ماشي ابداً Divergence →
طبعاً هي عمل جيبس إنى باخد
خطوات كبيرة فتحدها ثبتجي

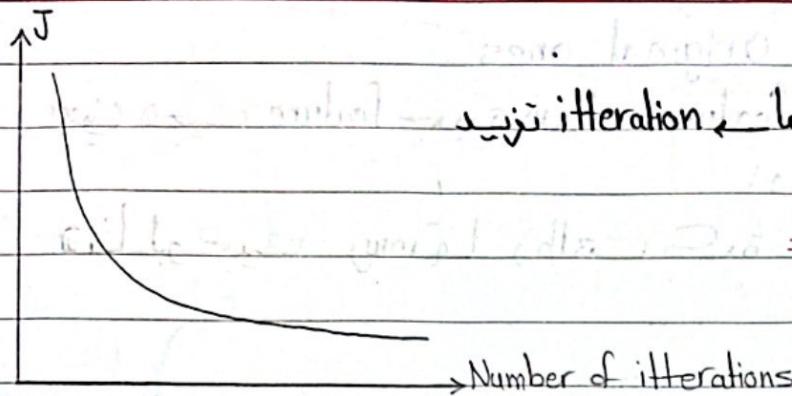


$$\theta_{\text{new}} = \theta_{\text{old}} - \alpha \sum_m h - y$$

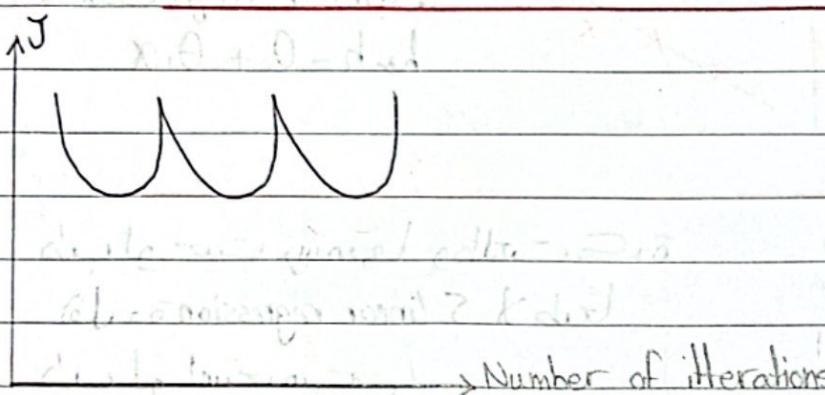
too small, too large } الحل لا يتحقق Solution: α small

أمثلة القيم الـ (0.001, 0.01, 0.1)
بناء على projects السابقة

- Make sure gradient descent is working correctly :



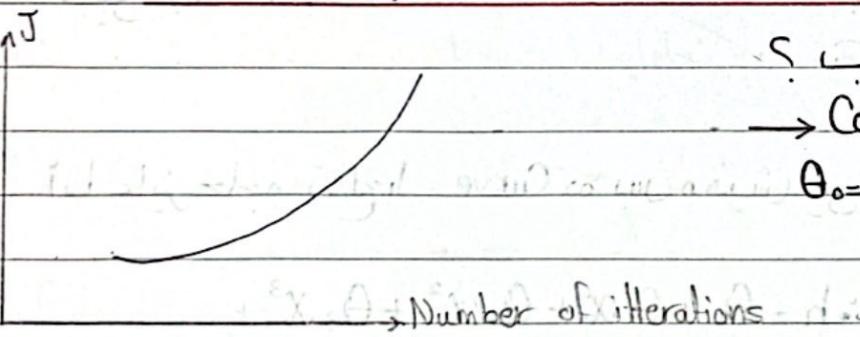
Correct model



هذا ايه يحصل؟ رايح جاي
↳ over shooting

α too large.

رجوع نظر طها شوقيه



هذا خط خالص طب ايه السبب؟
→ Code Error or Rule Error

$$\theta_0 = \theta_0 - \alpha \sum_{m=1}^M (h - y) \quad \text{يعني الطبيعي (y)}$$

+ انتفذ خط وخطي θ

*Feature Engineering

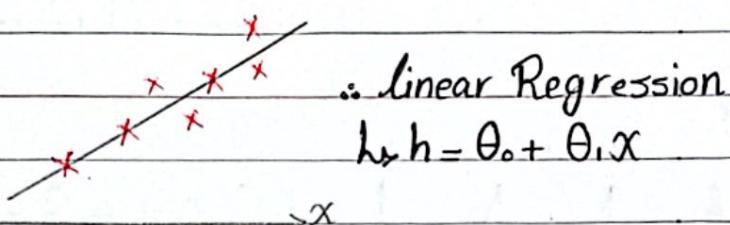
Extract new features from original ones

يحيى يجب بـ feature الجديدة من الـ features التي عندى

Size Price

x	y

هنا لو جيت رسمتها وطلبت كدة



Polynomial regression

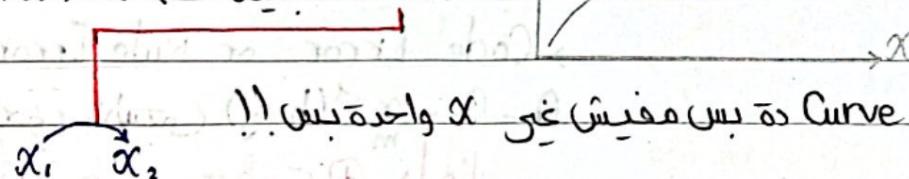
كتير احذور

اे هطلع من الـ feature الى عندي x

x^2, x^3, \dots ← feature جديدة

طب لو جيت رسمتها وطلبت كدة
 هل دة لـ linear regression

طب لو استخدمنـه
 Error جـداً



x	x^2	x^3 ...	y

$$\therefore h = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \dots$$

طب افرض المعادلة دي متبطنة بـ x
 هروح أزروه features تانية وأشوف ودهـا

أنا برسم الـ Data وأشوف على حسب الـ
 ططلع هـاشغل بـ ايـه؟

Classification

① Binary Classification

Binary → 2 Classes

ثنائي

مريض → 1

② Multi-Class Classification problem

لو عندي مجموعة صور (قطط، كلب، سدا)

3 Classes

مختلط بس 1, 0, 2

غير مريض → 0

$$y \in \{0, 1, 2\}$$

Tumor (ورم) → Malignant (1) خبيث

Benign (0) حميد

$$y \in \{0, 1\}$$

Logistic Regression: Binary Classification Algorithm

Classification

الخط المستقيم

Ex: Tumor → mali (1) خبيث

Ben (0) حميد

x

y

Classification → 0 or 1 ← output h_1

2 0

$h = \theta_0 + \theta_1 x$ ← linear reg.

3 0

1

$h < 0$ or $h > 1$ ← h_1

4 0

0.5

\rightarrow If $h > 0.5$ then $y = 1$ else $y = 0$

8 1

0

Threshold

Threshold ↓ 1 or 0 لازم

9 1

$h > \text{Threshold} \rightarrow 1$

10 1

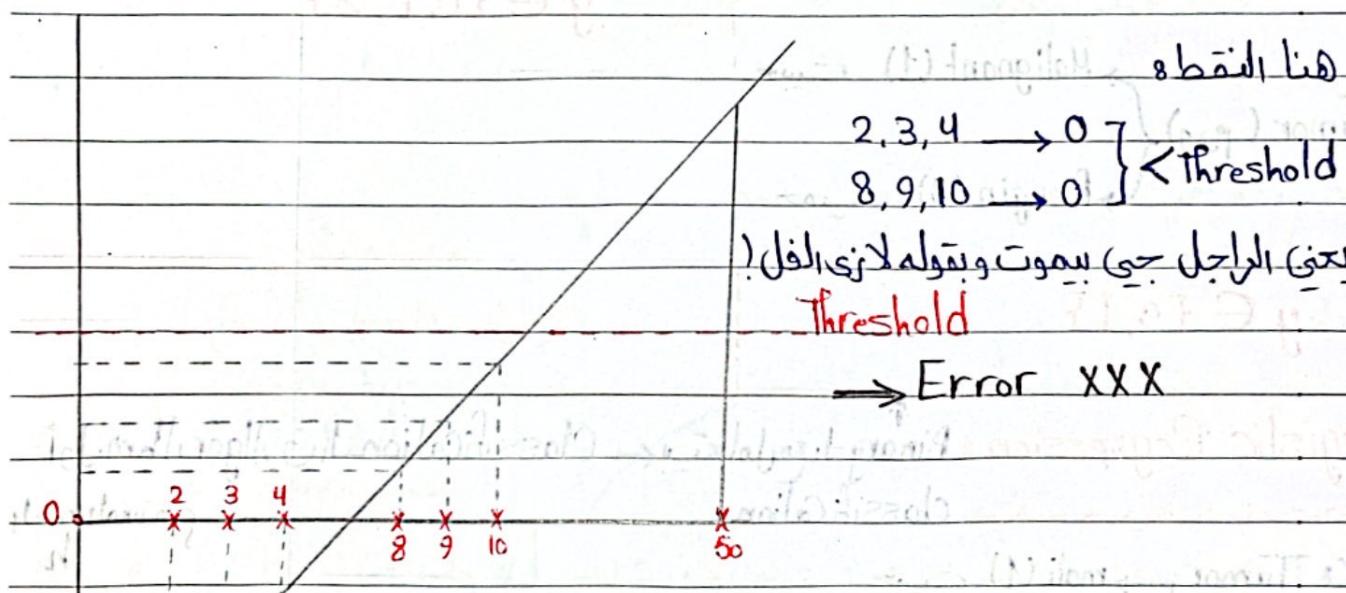
$h < \text{Threshold} \rightarrow 0$

more Ben, zero if $h < 0.5$ if $h > 0.5$ then $y = 1$ if $h = 0.5$ then $y = 0.5$

تاني دايم فكرة ال threshold ← حد فاصل، أنا عندي قيم مختلفة بانطبع منها إن الورم خبيث \leftarrow Ben 0 أو \leftarrow Mali 1 فقولنا ال threshold مثلاً بـ 0.5 أطبع أي قيمة ألم يغزو من 0.5 هتكون بـ zero وأي قيمة أكبر من أو تساوي 0.5 ه تكون بـ 1.

حل جميل وكل حاجة بس خلط مبغضه هبوز الدنما

$h = \theta_0 + \theta_1 x$ ← المشكلة في المعادلة بتاعة المعاكلة straight line ← ليه بيقاد لأن لما أزيد قيم ال x بشكل مختلف ← هياز على ال y وبالتالي الساق \rightarrow threshold زى المرسومة دى.



فكرة ال threshold كوبسحة حدّا لكن تمبيها على المعادلة دى $h = \theta_0 + \theta_1 x$. Error هبطعل كارثة لو حصل تغير في قيم x وبالتالي ال straight line كان وحش فحصل تشوه في المعاكلة لأن $h < 0$ أو $h > 0$ وأناعاشرة أحضرها بين 0, 1

وتحاخد المعادلة دي أعن فنها شوية

Binary Sigmoid

$$g(z) = \frac{1}{1+e^{-z}} ; -\infty \leq z \leq \infty ; 0 \leq g(z) \leq 1$$

→ Assume:

$$\textcircled{1} z=0, g(z) = \frac{1}{1+e^0} = \frac{1}{1+1} = 0.5$$

$$\frac{1}{\infty} = 0$$

$$e^0 = 1$$

$$\textcircled{2} z=\infty, g(z) = \frac{1}{1+e^{-\infty}} = \frac{1}{1} = 1$$

$$e^{\infty} = \infty$$

$$\textcircled{3} z=-\infty, g(z) = \frac{1}{1+e^{(-\infty)}} = \frac{1}{1+\infty} = \frac{1}{\infty} = 0$$

$$e^{-\infty} = 0$$

$$z=\infty \rightarrow 1$$

$$z=0 \rightarrow 0.5$$

لماذا هذه function هي مفيدة؟ إنها تأخذ القيم م hemisphere بين 0, 1

بدل ما كان يطلع Error بسبب إنها لا يمكن تطلع أكبر من 1 أو أصغر من 0

① $H(z) < d$

② $H(z) > d$

* Logistic Regression :

2 classes عددي بسيط Binary classification لוגستيك

Remember : Linear Regression

$$\cdot h = \theta_0 + \theta_1 x$$

$$\cdot J = \frac{1}{2m} \sum (h - y)^2$$

$$\cdot \theta_0 = \theta_0 - \alpha \frac{1}{m} \sum (h - y)$$

$$\cdot \theta_1 = \theta_1 - \alpha \frac{1}{m} \sum (h - y)x$$

→ logistic Regression :

$$\cdot g(z) = \frac{1}{1+e^{-z}} ; 0 \leq g(z) \leq 1$$

$$\cdot h = g(z) = \frac{1}{1+e^{-z}} ; 0 \leq h \leq 1$$

$$\cdot z = \theta_0 + \theta_1 x$$

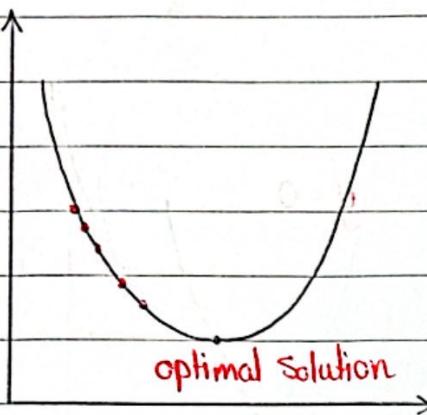
* Threshold :

$h \geq threshold \rightarrow 0 \leftarrow h$ إذا

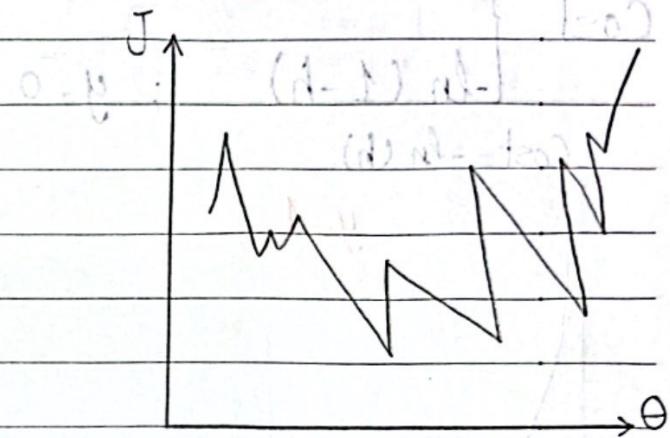
$h < threshold \rightarrow 1 \leftarrow h$ إذا

$$J = \frac{1}{2m} \sum (h - y)^2$$

linear Regression



logistic Regression



هذا القانون يمكّن لأن يقرب
optimal solution من

هذا يعني initial guess يكون في
يُعطي initial guess مناسب
optimal solution.

XXX Non Convex

$$h = \frac{1}{1 + e^{(\theta_0 + \theta_1 x)}}$$

هذا يعني يمكن الحصول على
أمثل optmal solution
لأن θ كل شئ وتحتها فوهة (يسعى)
استخدم قانون الـ $J = \frac{1}{2m} \sum (h - y)^2$

* والامتحان ليه $J = \frac{1}{2m} \sum (h - y)^2$ هو نفس في (logistic Regression)

لأنه يطلع كما initial guess
logistic

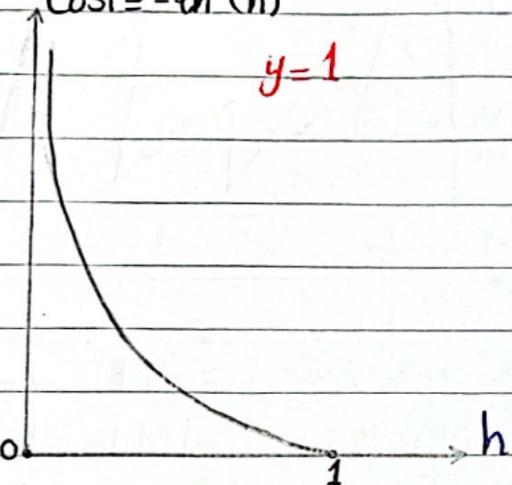
logistic Regressions

$$J = \frac{1}{m} \sum \text{Cost}$$

$$\text{Cost} = \begin{cases} -\ln(h) & ; y=1 \\ -\ln(1-h) & ; y=0 \end{cases}$$

$$\text{Cost} = -\ln(h)$$

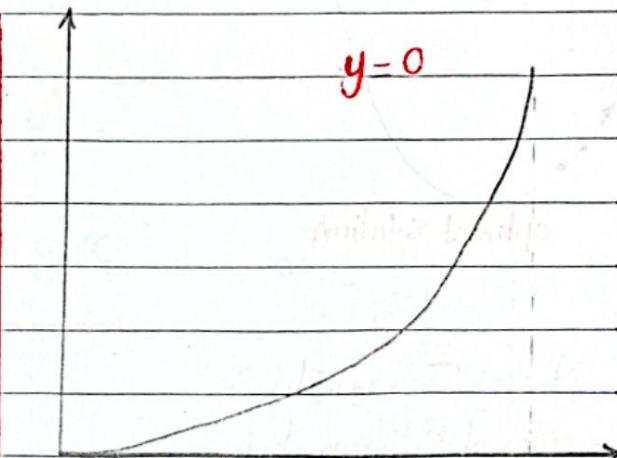
$y=1$



$y=1$

$$\text{Cost} = -\ln(h)$$

$$\begin{aligned} \rightarrow h=0 &\rightarrow \text{Cost} = \infty \\ \rightarrow h=1 &\rightarrow \text{Cost} = 0 \end{aligned}$$



$y=0$

$$\text{Cost} = -\ln(1-h)$$

$$\begin{aligned} \rightarrow h=0 &\rightarrow \text{Cost} = 0 \\ \rightarrow h=1 &\rightarrow \text{Cost} = \infty \end{aligned}$$

Error \uparrow كلما h يزيد عن الحقيقة
Error \downarrow كلما h يقل عن الحقيقة

Rule \leftarrow $\text{Cost} = -y \ln(h) - (1-y) \ln(1-h)$

* Minimize J \rightarrow Target

$\rightarrow \theta_0, \theta_1$ \rightarrow Cost \rightarrow لو كونسن هيلوا h كونسنه سعى

$$J = \frac{\sum \text{Cost}}{m}$$

\rightarrow Gradient descent Algorithm

$$\theta_{\text{new}} = \theta_{\text{old}} - \alpha \frac{\partial J}{\partial \theta}$$

$$\theta_0 = \theta_0 - \frac{\alpha}{m} \sum (h - y)$$

$$\theta_1 = \theta_1 - \frac{\alpha}{m} \sum (h - y)x$$

* Summary:

$$\cdot z = \theta_0 + \theta_1 x$$

$$\cdot h = \frac{1}{1 + e^{-z}}$$

$$\cdot J = \frac{\sum \text{Cost}}{m}$$

$$\cdot \text{Cost} = -\ln(h) ; y=1$$

$$\cdot \text{Cost} = -\ln(1-h) ; y=0$$

$$\cdot \theta_0 = \theta_0 - \frac{\alpha}{m} \sum (h - y)$$

$$\cdot \theta_1 = \theta_1 - \frac{\alpha}{m} \sum (h - y)x$$

Example Consider the following training data for logistic regression:

You are using logistic regression and values of thetas came out to be as: $\theta_0 = 2, \theta_1 = 1$

x	y
3	1
5	1
10	0
12	0

-Draw the decision boundary

-Compute the total error.

-Find θ_0 and θ_1 for the next iteration, assume $\alpha = 0.1$

Solution

x	y	z	h	(h-y)	(h-y)x	Cost
3	1	5	0.99331	-0.00669	-0.02007	6.71×10^{-3}
5	1	7	0.99909	-0.00091	-0.00455	9.1×10^{-4}
10	0	12	0.99999	0.99999	9.9999	11.51
12	0	14	0.999999	0.999999	11.999988	13.82
		Σ	1.992	21.98	25.34	

$$\cdot J = \frac{\sum \text{Cost}}{m} = \frac{25.34}{4} = 6.33 \#$$

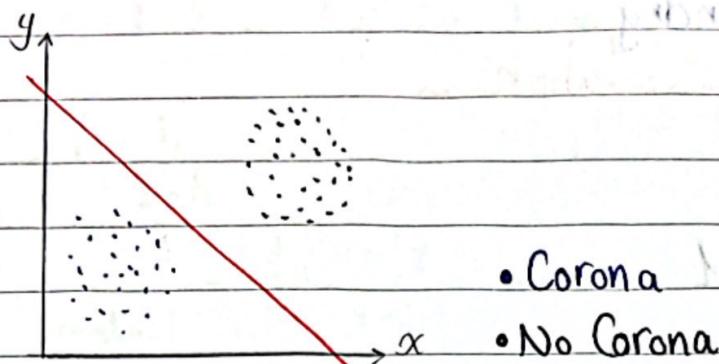
$$\cdot \theta_0 = \theta_0 - \frac{\alpha}{m} \sum (h-y)$$

$$\theta_0 = 2 - \frac{0.1}{4} [1.992] = 1.95 \#$$

$$\cdot \theta_1 = \theta_1 - \frac{\alpha}{m} \sum (h-y)x$$

$$\theta_1 = 1 - \frac{0.1}{4} [21.98] = 0.45 \#$$

Decision boundary



الخط، الفاصل بين classes
يطلع من المدلول حالات اعلى اسماها

* Decision boundary of logistic Regression

$$\cdot h = \frac{1}{1+e^{-z}} \implies z = \ln \frac{h}{1-h}$$

$\cdot Z = \theta_0 + \theta_1 X \leftarrow$ Decision boundary || پادل

• Thresholding و من اهم الطرق.

Assume Threshold = 0.5

$$Z = \ln \frac{0.5}{1-0.5} = \ln \frac{0.5}{0.5} = \ln 1 = 0 \text{ # at threshold } ①$$

$$\text{كمثال: } \text{افتراض: } z = \theta_0 + \theta_1 x \implies z = 1 + 2x \quad (2)$$

$$1 + 2x = 0$$

②, ①. جو

decision boundary دوسری سطح

Ex: Assume the model is trained by Logistic Regression

$$z = 1 + 2x_1 + 3x_2 \text{ and threshold} = 0.5$$

find the decision boundary

Solution

$$z = \ln \frac{h}{1-h}$$

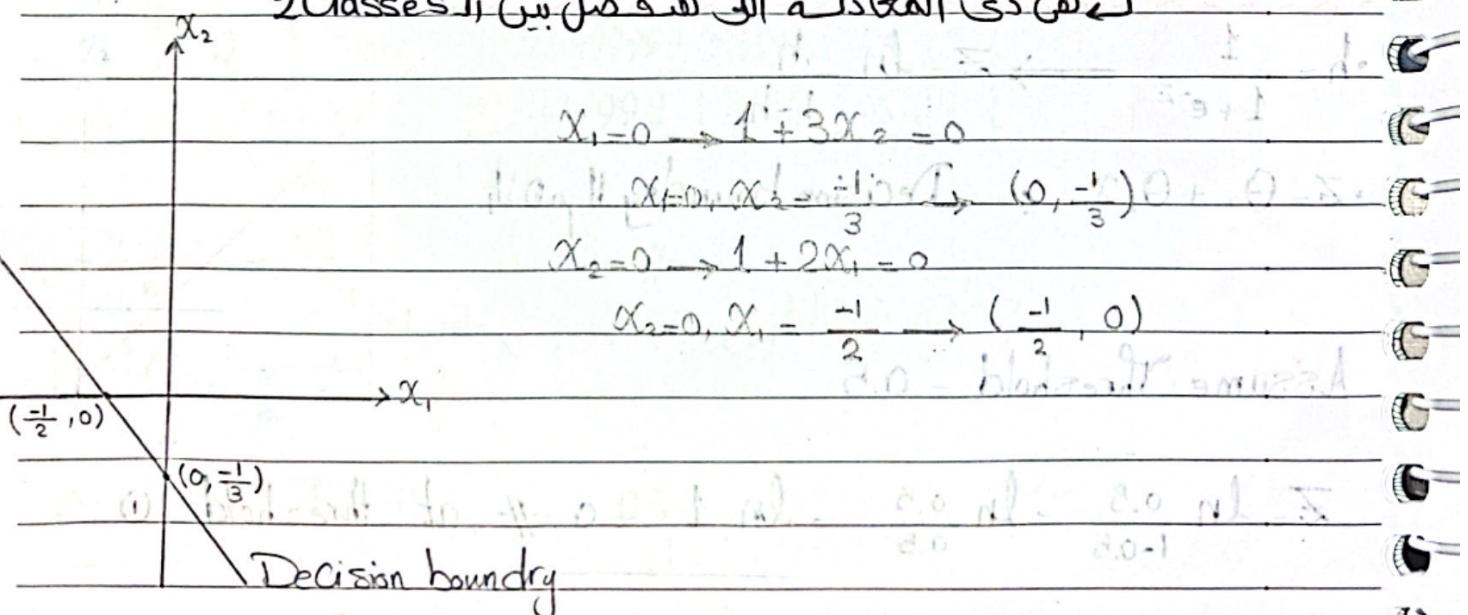
$$\frac{z}{\text{threshold}} = \ln \frac{0.5}{1-0.5} = \ln 1 = 0$$

$$\frac{z}{\text{threshold}} = 0$$

$$z = 1 + 2x_1 + 3x_2$$

$$1 + 2x_1 + 3x_2 = 0 \leftarrow \text{Decision boundary}$$

2 classes | الـ 0 و 1 | ← هـ دـ يـ الـ مـ اـ حـ اـ لـ الـ هـ مـ اـ لـ بـ يـنـ



Decision boundary

Ex8 Assume the model is trained by logistic Regression

$$\theta_0 = 1, \theta_1 = -4, \theta_2 = 3 \text{ and threshold} = 0.7$$

Find the decision boundary

Solution

$$z = \ln \frac{h}{1-h}$$

(A=1) for availability

(A=0) for patient

$$z|_{\text{threshold}} = \ln \frac{0.7}{1-0.7} = 0.8$$

$$z|_{\text{threshold}} = 0.8, z = 1 - 4x_1 + 3x_2$$

$$1 - 4x_1 + 3x_2 = 0.8 \rightarrow \text{Decision boundary}$$

Proof:

$$h = \frac{1}{1 + e^{-z}}$$

$$(1 + e^{-z})h = 1$$

$$1 + e^{-z} = \frac{1}{h}$$

$$e^{-z} = \frac{1}{h} - 1 = \frac{1}{h} - \frac{h}{h}$$

$$\ln e = 1$$

$$\ln x^y = y \ln x$$

$$e^{-z} = \frac{1-h}{h}$$

Take \ln to both sides

$$-z \ln e = \ln \frac{1-h}{h}$$

$$z = -\ln \frac{1-h}{h}$$

$$\Rightarrow z = \ln \frac{h}{1-h}$$

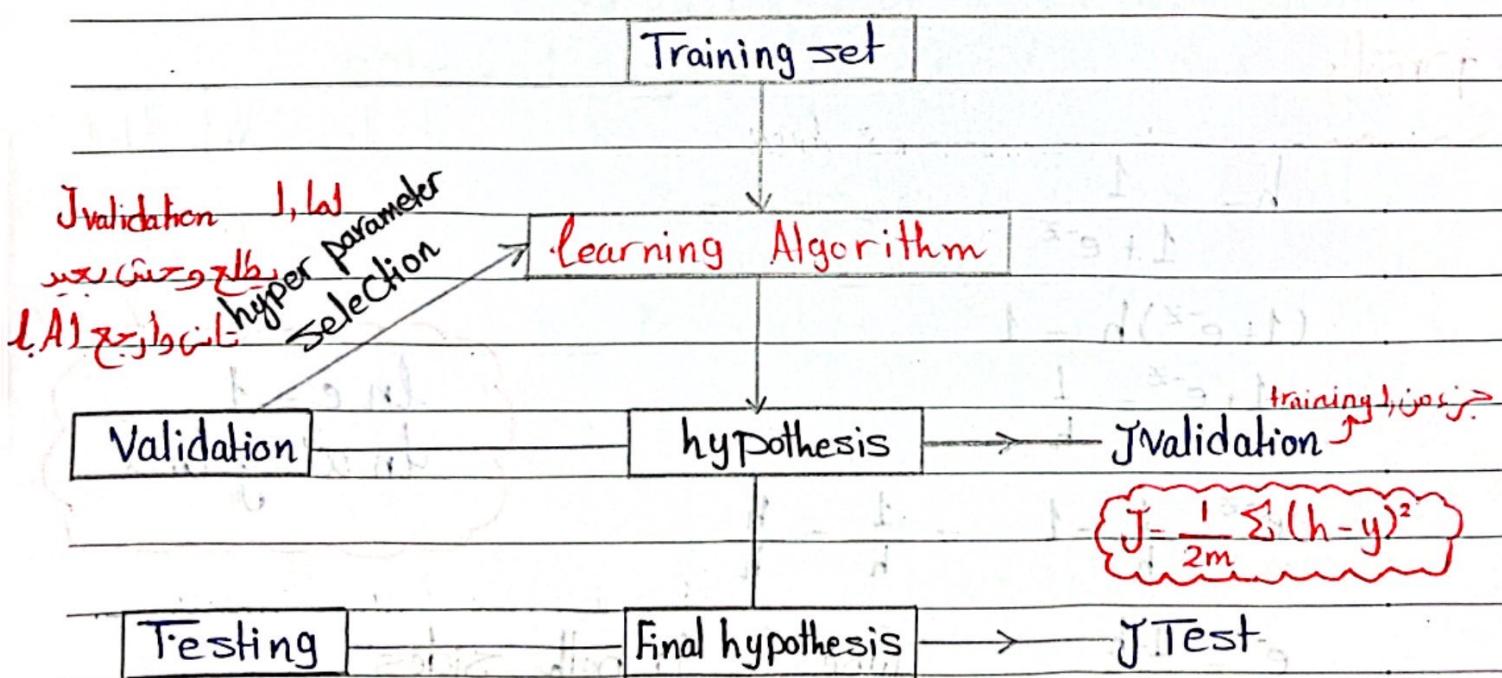
*Model Evaluations

Dataset \rightsquigarrow 3 parts

- Training set (70%)
- Validation set (15%)
- Testing set (15%)

{ex} $m = 1000$

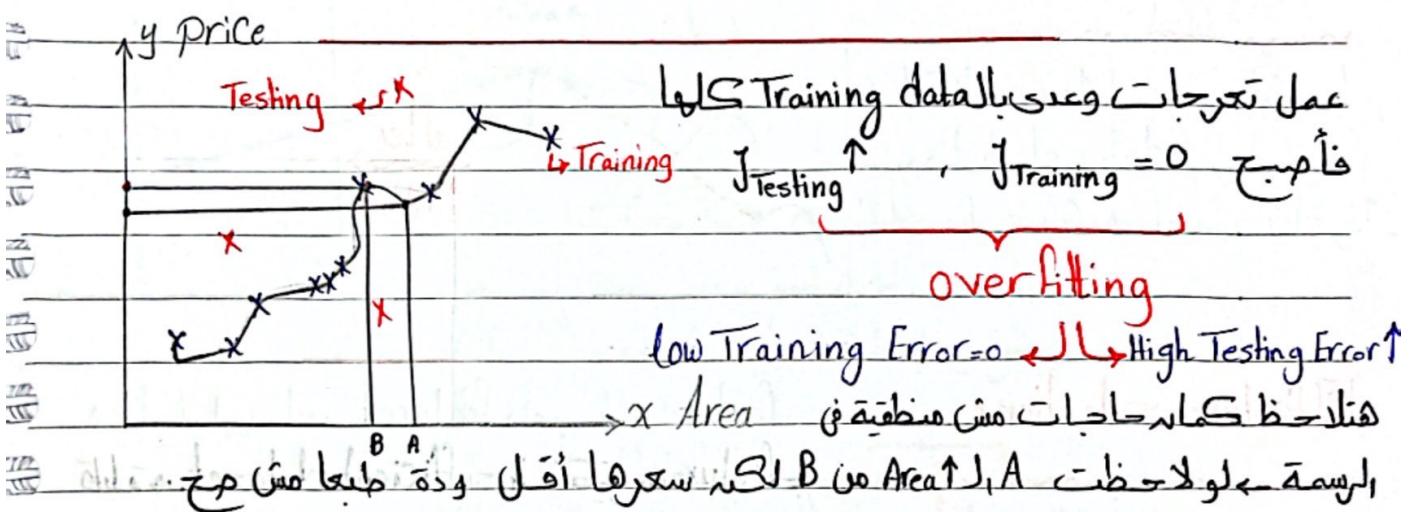
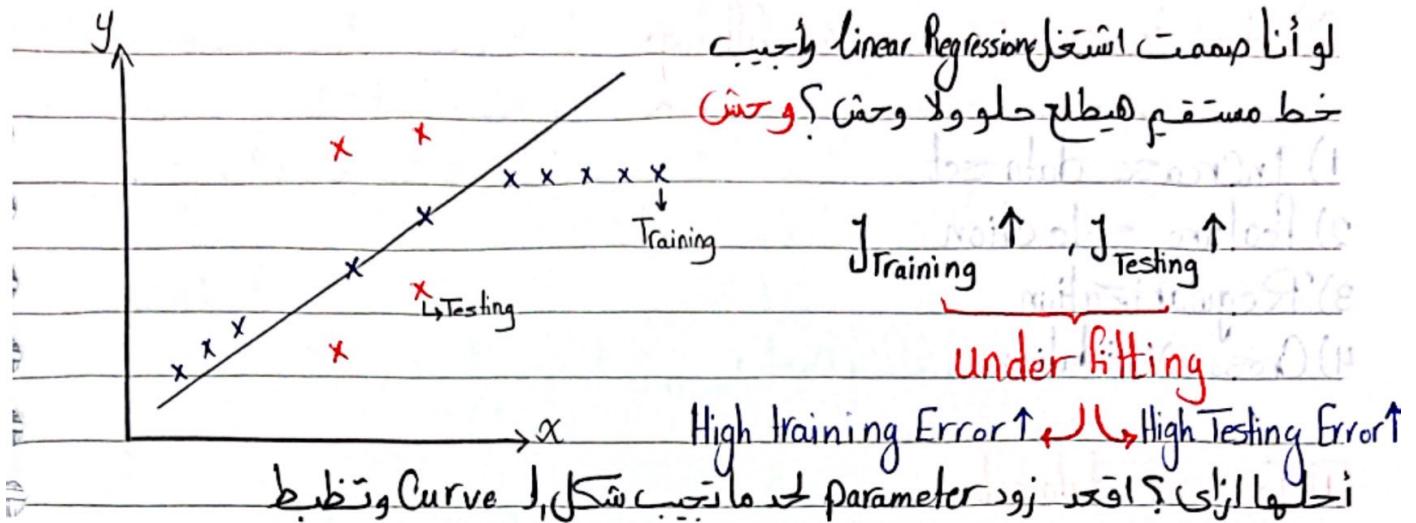
- Training $\rightarrow 700$
- Validation $\rightarrow 150$
- Testing $\rightarrow 150$



$$\frac{1}{2m} \sum (h - y)^2 = \left\{ \begin{array}{l} J_{\text{Training}} \\ J_{\text{validation}} \\ J_{\text{Testing}} \end{array} \right\}$$

①
②
③

$J = \frac{1}{2m} \sum (h - y)^2$



Exam question 8 How to know that your model has the overfitting issue?

Ans: 1- if the Training Error is low
and the Testing Error is high

لدينا خط بسيط, لو اخترنا مجموعه من المعلمات 就是 underfitting, 就是 overfitting.

Model Evaluation.

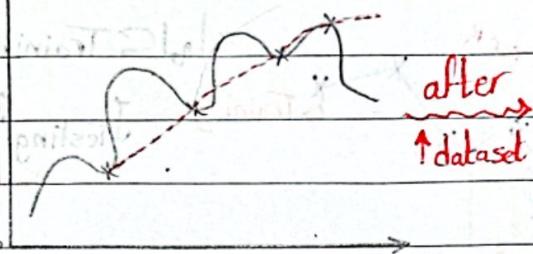
Q) How to over come over fitting: Just consider more

الحلول دى بالترتيب ادأ بالاول وسوف

- 1) Increase data-set
 - 2) feature selection
 - 3) Regularization
 - 4) Cross Validation

II Increase dataset

هناك اربعة خطوات بين هذه الخطوات
لارزونا dataset لبيانات
الخطوات هي Curve او Fit من المفترض



12 | Feature Selection

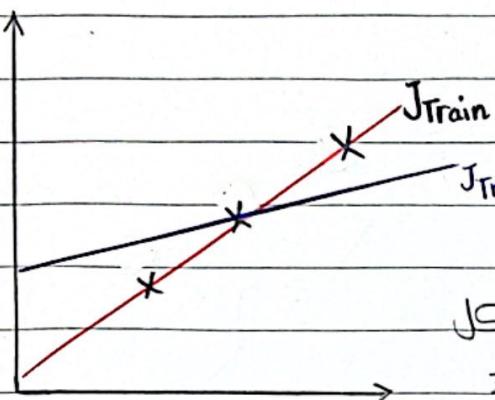
features using features with Lables

features, insufficient dataset.

هـ بـ اـ شـ وـ فـ لـ اـ يـهـ الـ سـاحـاـتـ الـ مـعـمـدـةـ وـ خـاـلـهـ اـ وـ جـيـنـ

3) Regularizations

عندما $J_{Train} = 0, J_{Test} \uparrow \uparrow$ كانت ايه؟ overfitting
 كل شوية يقتصر يقل J_{Test} يعني تنحال مع بساده ان عليا
 لـ regularization
 J_{Train} قليلة جداً لكن J_{Test} عالية وهذا يعني دور
 في وسطن الدنيا شوية $\downarrow J_{Test}, \uparrow J_{Train}$ ، ويقتل



٤- overfitting بمعنى لخبط اذا حصل عليه عسانه
ain على Data على لخبط تبكي كاللجزي ماقولنا
JTrain قليل جداً فهو راح معن ورسم لخبط
الازرق خايم الـ حصل ؟ زودوا JTrain
طب ازاي ومحارله كل Gradient descent
Zero هدفها انهم اتخلى Error اقل حاجة ←
طب ابي الحل ؟ هخمن في العادلة دى شوية بقا

$$J = \frac{1}{2m} \sum (h - y)^2 + \boxed{\downarrow}$$

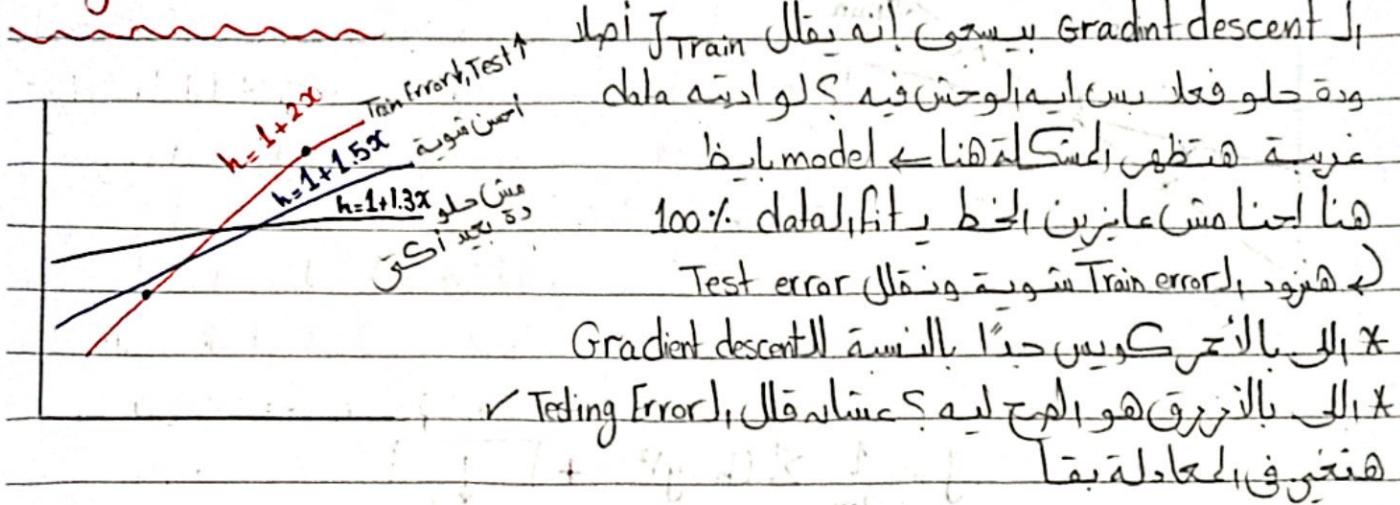
regularization
parameter

Overfittings

J_{Train} قليلة جداً، J_{Test} عالية

- 1-increase dataset
- 2-feature selection
- 3-Regularization
- 4-Cross-validation

Regularization



Ex:

x	y	h	$h = 1 + 2x$
1	3	3	$J = \frac{1}{2m} \sum (h-y)^2 = \text{zero}$
2	5	5	كله شغال مع وتمام بعـ زى ما قولنا اى data غريبة هيطلع Error هنجو شوية في المعادلة بقا

$$h = \theta_0 + \theta_1 x$$

اعطى عاليين نقل ايه؟ قبل الخط
فالمفهوم أنتك من θ_0, θ_1

Regularization
Parameter

لابد θ_0, θ_1 جزء مقطوع من
دور الاعدات من اى xx

L من الرسمة الى فات

التاريخ:

الموضوع:

$$at: h = 1 + 2x$$

$$at: h = 1 + 1.5x$$

$$at: h = 1 + 1.3x$$

x	y	h	$(h-y)^2$
1	3	3	0
2	5	5	0

$$J = 0 + \frac{1}{4} (4) = 0$$

x	y	h	$(h-y)^2$
1	3	2.5	0.25
2	5	4	1

$$J = \frac{1}{4} (1.25) + \frac{1}{4} (1.5)^2 = 1.25$$

x	y	h	$(h-y)^2$
1	3	2.3	0.49
2	5	3.6	1.96

$$J = \frac{1}{4} (2.5) + \frac{1}{4} (1.3)^2 = 2.45$$

الخط الأسود # الخط الآخر

Gradient descent كويس لا يحول Test وحده لا

J = 0.875

Error دة أحسهم فعل من حيث زاد عن

الخط الأسود # الخط الآخر

Error دة أسوء واحد لانه زاد عن

Gradient descent بداعي

$$\theta_0 = ?$$

$$\theta_1 = ?$$

$$J = \frac{1}{2m} \sum (h-y)^2 + \frac{\lambda}{2m} \theta_1^2$$

$$\theta_{0,\text{new}} = \theta_{0,\text{old}} - \frac{\alpha}{m} \sum (h-y)$$

$$\theta_{0,\text{new}} = \theta_{0,\text{old}} - \alpha \frac{\partial J}{\partial \theta_0}$$

جاء بالتفاضل بالنسبة لـ θ_0

$$\theta_{1,\text{new}} = \theta_{1,\text{old}} - \alpha \left[\frac{2}{2m} \sum (h-y)x + \frac{2\lambda}{2m} \theta_1 \right]$$

$$\theta_{1,\text{new}} = \theta_{1,\text{old}} - \alpha \frac{\sum (h-y)x}{m} - \frac{\alpha \lambda}{m} \theta_1$$

$$\theta_{1,\text{new}} = \theta_{1,\text{old}} \left[1 - \alpha \lambda \right] - \alpha \frac{\sum (h-y)x}{m}$$

بنأخذ جزء من θ_1

لأن θ_1 كروميوب في

Regularization

If we have 2 features $\rightarrow x_1, x_2$

$$J = \frac{1}{2m} \sum (h - y)^2 + \frac{\lambda}{2m} [\theta_1^2 + \theta_2^2]$$

*Overfitting in Classification

- Training accuracy
- Testing accuracy

*logistic Regression

كنا نطالع بالـ J وفي الممكن بـ J بالـ y \rightarrow J_{Training} $\neq J_{\text{Testing}}$

x	y	h	after threshold
1	1 ✓		
0	0 ✓		
0	1 ✗		
0	0 ✓		
1	0 ✗		

$$\text{accuracy} = \frac{3}{5} * 100$$

النحوات المصححة (صفر وواحد) \rightarrow عددهم \rightarrow

او اننا سنتخال Regression مـولـنا ازـاي اعـرف

J_{Testing} قـليلـاً جداً ، فـحالـة بـ J_{Training} \rightarrow J_{Testing}

طبعـاً بالـ J_{Training} يـعـني J_{Testing} \rightarrow J_{Testing} \downarrow \rightarrow Overfitting \uparrow
 Training accuracy \uparrow \leftarrow \rightarrow Testing accuracy \downarrow \leftarrow
 data غـيرـة \rightarrow \rightarrow

Training accuracy \downarrow \rightarrow underfitting.
 الـ J_{Training} قـليلـين \rightarrow Testing accuracy \downarrow

Regularization in Case of logistic Regressions

$$J = \frac{\sum \text{Cost}}{m} + \frac{\lambda}{2m} \theta_1^2$$

مقدار J يعتمد على جمع Cost

، Regularization parameter

$$\theta_0 = \theta_0 - \frac{\alpha}{m} \sum (h - y)$$

$$\theta_1 = \theta_1 [1 - \frac{\alpha \lambda}{m}] - \frac{\alpha}{m} \sum (h - y) x$$

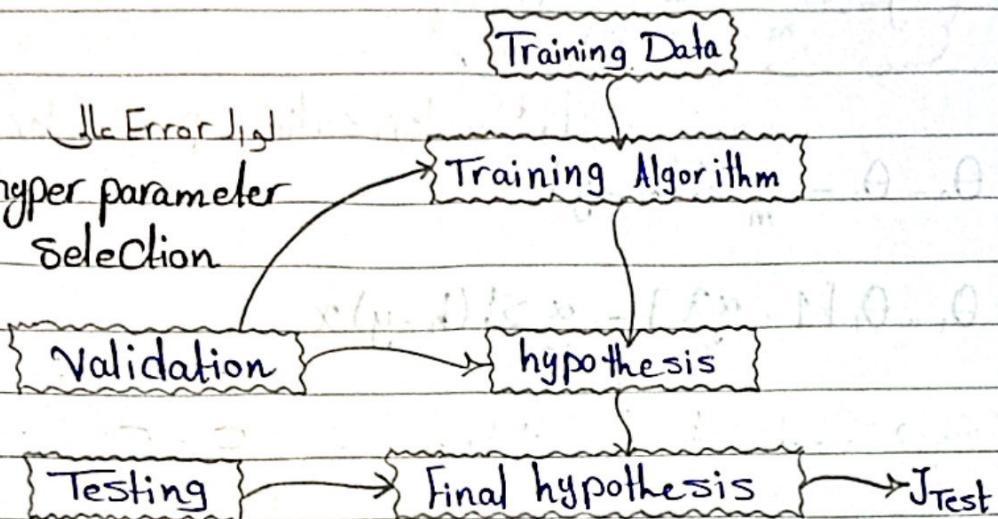
وخلصنا إلى نفس المعادلات إلا أن الترميم غير مكتوب حسبما هو الحال في
logistic (non linear) لأن حسابها مختلف عن linear

$$h = \frac{1}{1 + e^{-z}} \quad \leftarrow \quad h = \theta_0 + \theta_1 x$$

٤) Cross Validation

اخذنا المقال فاتت evaluation model

Testing, Validation, Training ← data لـ linear وقسمنا



هنا في مسكة لـ data قلنا له Validation ← data قلنا له Validation
جينا له Test اقينا له Test ← data هنوز ← Cross Validation

• Cross Validation K fold

$5 \leq K \leq 10$ ← K projects

hyper parameter

Ex: $m=1000$, $K=5$ → 5 عينات

Test | Train

200	200	200	200	200
-----	-----	-----	-----	-----

$\frac{1000}{5} = 200$ كل جزء من 5 يقسم 200 → 200 في كل جزء

Train Test | Train

200	200	200	200	200
-----	-----	-----	-----	-----

| Train | Test | Train

200	200	200	200	200
-----	-----	-----	-----	-----

200 row data لـ Test يجيء أول مرة

200 row data Train ، ثاني مرة تأتي 200 Train و 200 Test

Train | Test | Train

200	200	200	200	200
-----	-----	-----	-----	-----

بالنهاية نت خاتمة يتدرب على كل وحدة حاجة طيبة

Train | Test

200	200	200	200	200
-----	-----	-----	-----	-----

من السكل الى فات كل مستطيل هي طبع J_{Test}
 ← كدة عندي كاً J_{Test} ؟ 5
 ← كاً 5 accuracy

J_{Test} ←
 accuracy ← Average report بمن؟ ← حمد

* الخطوات الى عملها دى ضمن model evaluation بعد ما ظبطت:
 خلاص هتاخذ J_{Test} كلها على بعضها تدريها على learning Algorithm.
 لابه كانت المسكلة ان J_{Test} كل شوية يحمل Validation ساول يظبطه وفي الآخر كسر فاحنا دن ظبطه في الطريقة الى فات دى ويندين أدخل J_{Test} كلها في الآخر على Training data كأنها learning Algoritm.

Evaluation Metrics

متراليج بيريد طاجة حلوو ولا جسته

1 Regression

$$MSE = \bar{y} = \frac{1}{2m} \sum (h - y)^2$$

$$RMSE = \sqrt{\bar{y}} = \sqrt{\frac{1}{2m} \sum (h - y)^2}$$

Root Mean Square Error

ex: Data training $\rightarrow h = 1000 + 1000x$

Test data

$1000 + 1000x$

x	y	h	h-y	(h-y) ²
2	2300	3000	700	490000
3	3400	4000	600	360000
4	5200	5000	-200	40000
5	5600	6000	400	160000
		Σ	1050000	

$$MSE = \frac{1}{2m} \sum (h - y)^2 = \frac{1}{8} * 1050000 = 131250$$

$$RMSE = \sqrt{MSE} = \sqrt{131250} = 362.28$$

2 Classification \rightarrow accuracy, recall, precision, F1-Score

Confusion matrix: binary classification \rightarrow 2 classes

yes \downarrow No

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} * 100$$

$$\text{recall} = \frac{TP}{TP + FN} * 100$$

$$\text{precision} = \frac{TP}{TP + FP} * 100$$

$$\text{F1-Score} = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

Example:

$$\cdot \text{accuracy} = \frac{120 + 50}{120 + 50 + 10 + 20} * 100 \\ \hookrightarrow 85\%$$

$$\cdot \text{recall} = \frac{120}{120 + 10} * 100 = 92.3\%$$

$$\cdot \text{precision} = \frac{120}{120 + 20} * 100 = 85.7\%$$

$$\cdot \text{F1-Score} = \frac{2 * 85.7 * 92.3}{85.7 + 92.3} = 88.9\%$$

		Actual	
		Yes	No
predicted	Yes	TP	FP
	No	FN	TN

positive \leftarrow P \leftarrow yes \rightarrow predicted 1,
negative \leftarrow N \leftarrow No \rightarrow predicted 2

جيئي - وانج سی \leftarrow \downarrow \downarrow
T P
F N

True \leftarrow yes \rightarrow yes \rightarrow predicted
False \leftarrow no \rightarrow yes \rightarrow
True \leftarrow no \rightarrow no \rightarrow predicted

		Actual	
		spam	Notspam
predicted	spam	120 TP	20 FP
	Notspam	10 FN	50 TN

$$\rightarrow \text{recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

الـ recall مهم بالـ recall
يعني لو الدراسة تتطرق مخاتلة على
الناس اللي قولت لهم Negative واجابي علشان
يعني لو بدرس معرف لهم بالنسبة لـ recall
أيـ بلـ recall كارثة لو أنا قولت محسن هوـ المرض وهو عنده فـ FN ↓

$$\rightarrow \text{precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

الـ precision مهم بالـ precision
أنا بنـا، وجهـ حـ قالـ عـاينـكـ تـعـالـيـ model
يـقولـ السـ خـ صـ دـ هـ يـقـرـرـ يـسـدـ القرـفـ ولاـ اـقـلـ ماـذـيـ فالـ وـ دـيـلـ سـقـولـ يـقـوـيـ يـقـوـيـ False Positive يعنيـ إـجـابـيـ عـلـشـانـ FP ↓ ، precision اـنـ لـ FP ↓

FP & FN

accuracy

balanced Data

F1-Score

Imbalanced Data

فـ هـيـاـ dat~set
→ 8 yes, 2 no

كـ مـعـنـوـنـهـ تـواـزنـهـ

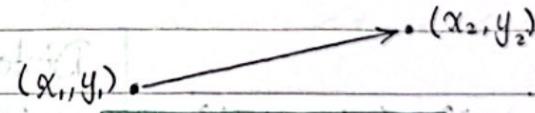
$$\text{AUC} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

$$\text{AP} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

K-nearest neighbour (KNN) hyperparameter $\leftarrow K$

Classification

Regression



$$D = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

training Algorithm (خوارزمية التعلم)

Classification :

- ① Find distance
- ② Find rank \rightarrow ascending order
- ③ output according to K (majority)

Regression :

- ① Find distance
- ② Find rank
- ③ output according to K (average)

antibi(1)

(2)

(3)

normal = 8.0 P.T.L

high risk = 11.1 - undifferentiated

B.P.

6-0 P.T.L

A.R.C.B

high risk differentiated
normal: high risk

Classification Example

	Distance	Rank	x_1	x_2	Class
$\sqrt{(167-170)^2 + (51-57)^2}$	6.7	5	167	51	UW
13	8	182	62	N	
13.4	9	176	69	N	
7.6	6	173	64	N	
8.2	7	172	65	N	
(الباقي)	4.1	4	174	56	UW
1.4	1	169	58	N	
3	3	173	57	N	
2	2	170	55	N	

Steps:

① Distance

N: Normal

② Rank رتب ترتيب حسب الأقرب

find the output when

③ $K=3 \rightarrow 3$ neighbour خارج أقرب

$x_1 = 170$

$\downarrow 1.4, 2, 3 \Rightarrow$ Normal

$x_2 = 57$

neighbours 1, 2, 3 \rightarrow output

$K=3 \leftarrow ③$ خارج أقرب



$K=5 \rightsquigarrow 1, 2, 3, 4, 5$

Normal

UW

يُحدّد على أساس الأغلبية output 1,

\rightarrow predicted output: Normal

Regression Examples

	x_1	x_2	y	Distance	Rank
	7	7	6	$\sqrt{(7-2)^2 + (7-1)^2} = 7.81$	4
	7	4	3	$\sqrt{(7-2)^2 + (4-1)^2} = 5.83$	3
	3	4	2	$\sqrt{(3-2)^2 + (4-1)^2} = 3.16$	2
	1	3	1	$\sqrt{(1-2)^2 + (3-1)^2} = 2.23$	1

find the output when:

$$x_1 = 2$$

$$x_2 = 1$$

$$K = 3$$

Solution

predicted output = $\frac{3+2+1}{3} = 2$
 according to K

(average $\rightarrow \textcircled{y}$)

Note: output in regression

① $K = \sqrt{N}$
 Num of training example

② Cross Validation

To get K with best performance
 (accuracy \uparrow , error \downarrow)

ازای اختار

Decision Tree

- predictive model

- used for:

↳ Regression (CART Algorithm)

↳ Classification (ID3 Algorithm)

Ex:

Decision Tree

weight	height	class output
?	?	Male - Female
?	?	?
?	?	?
?	?	?

Height > 180 Cm.

yes

no

male

weight > 80

yes

no

male

female

Height = 190

weight = 85

→ Male

Height = 175

weight = 90

→ Male

Height = 150

weight = 60

→ Female

*Feature Selection :

لماذا الـ Feature height و weight يعطى Tree better results؟
يجب عليهما أن يكونا بـ Height.

XX random X عشوائية

Measured by :

↳ Information Gain ✓

↳ Gini index

· Entropy: impurity في شوائب X pure ← عكسها

$$0 \leq E < 1$$

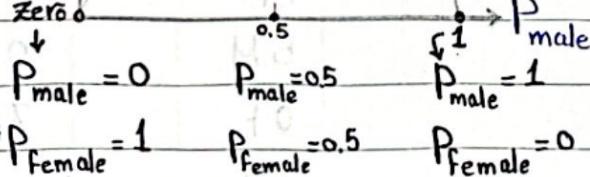
height	weight	0/p

Height	Weight	Class
		female

E

1.

Zero



Height	Weight	Class
		female
		male
		male
		female

$$E=1$$

E=0 يعني طبقاً لـ Entropy أقل قيمة في Feature weight

أدنى قيمة في Feature weight
عندما يكون المale والfemale متساوياً

$$\{ E = -\sum P \log_2 P \} \quad P: \text{probability}$$

height	weight	class
		female
		male
		female
		female

$$\rightarrow p(\text{male}) = \frac{1}{4}, p(\text{female}) = \frac{3}{4}$$

$$E(S) = - \left(\frac{1}{4} \log_2 \frac{1}{4} + \frac{3}{4} \log_2 \frac{3}{4} \right)$$

↓ dataset

Information Gain (IG)

measures reduction in Entropy (E↓)

IG↑ → best

height	weight	output
short	light	1
short	heavy	1
tall	light	0

height → output 1, 0

S	F Female	M Male
S ₁	4M	3M
S ₂	4F	3F

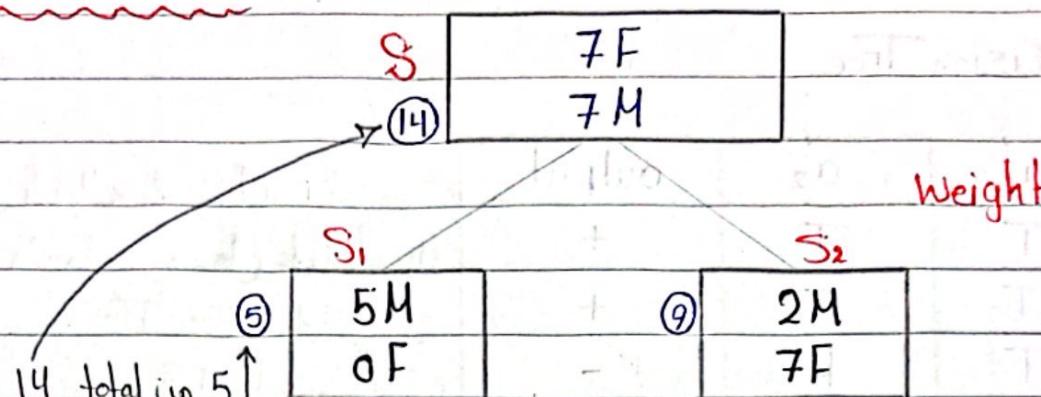
weight → output 1, 0

S	F Female	M Male
S ₁	5M	2M
S ₂	0F	7F

- No a best split with set min.
- IG↓ ← the class الناتج واحد يعني في سوابق E↑

- Entropy reduced
- IG↑

IG Calculation حساب المؤسدة



$$IG(S, \text{weight}) = E(S) - \frac{5}{14} E(S_1) - \frac{9}{14} E(S_2)$$

$$E(S) = -\left[\frac{7}{14} \log_2 \frac{7}{14} + \frac{7}{14} \log_2 \frac{7}{14}\right] = 1$$

$$E(S_1) = -\left[\frac{5}{5} \log_2 \frac{5}{5} + \text{zero}\right] = 0$$

$$E(S_2) = -\left[\frac{2}{9} \log_2 \frac{2}{9} + \frac{7}{9} \log_2 \frac{7}{9}\right] = 0.764$$

$$IG = 1 - \frac{5}{14}(0) - \frac{9}{14}(0.764) = 0.508$$

ExampleDraw decision Tree

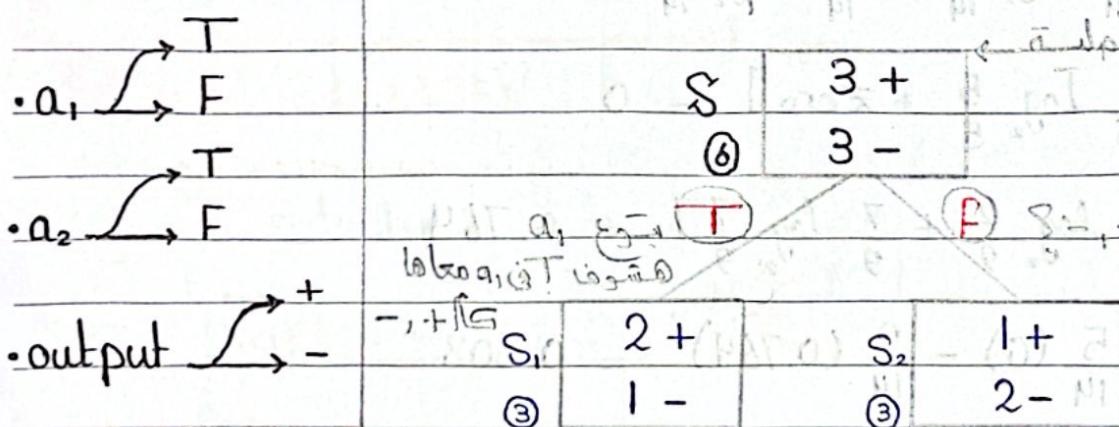
instance	a ₁	a ₂	output
1	T	T	+
2	T	F	+
3	T	F	-
4	F	F	+
5	F	T	-
6	F	T	-

حل المسألة على 2 parts

أول واحد ينتمي إلى a₁وأحسب IG يعتمد على a₁

وأحسب IG وأشوف أنه أحسن

أحسن

Solution

$$E(S) = - \left[\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6} \right] = 1$$

$$E(S_1) = - \left[\frac{2}{3} \log_2 \frac{2}{3} + \frac{1}{3} \log_2 \frac{1}{3} \right] = 0.9183$$

$$E(S_2) = - \left[\frac{1}{3} \log_2 \frac{1}{3} + \frac{2}{3} \log_2 \frac{2}{3} \right] = 0.9183$$

$$IG(S, a_1) = 1 - \frac{3}{6} * 0.9183 - \frac{3}{6} * 0.9183 = 0.0817$$

a_2

S	3 +	3 -
⑥	3 -	

T

F

S ₁	2 +	② 1 +
④	2 -	1 -

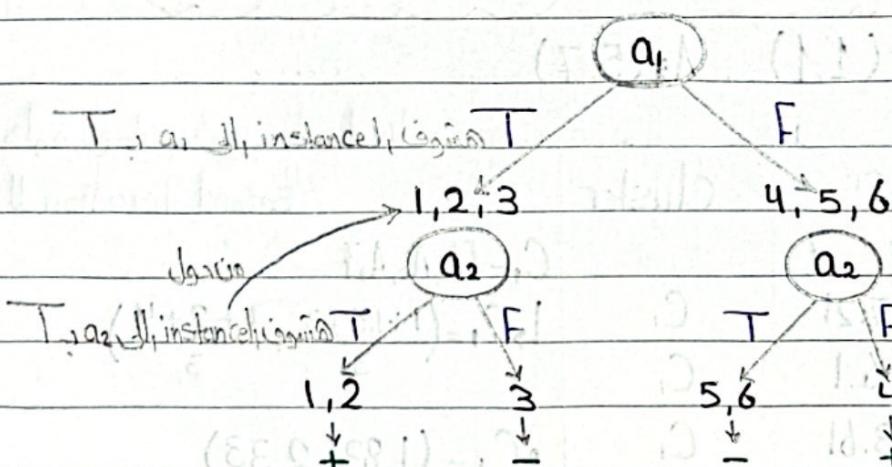
$$E(S) = 1$$

$$E(S_1) = -\left[\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4}\right] = 1$$

$$E(S_2) = -\left[\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2}\right] = 1$$

$$\cdot IG(S, a_2) = 1 - \frac{4}{6} * 1 - \frac{2}{6} * 1 = 0$$

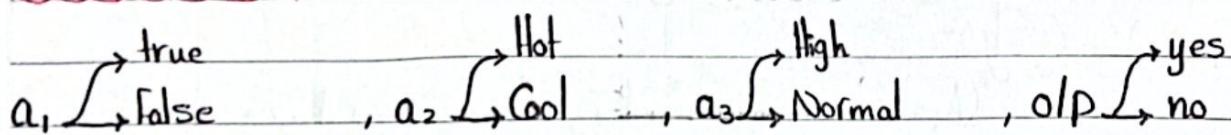
Decision Tree $IG(S, a_i) > IG(S, a_2) \rightarrow a_1$ the best i values



Ex 8 Draw Decision Tree

IG (A₁) = 0.61 \rightarrow IG (A₁) خاص كلوحة لها 3 تقسيمات يعني له 3 Features ينبع من

instance	a ₁	a ₂	a ₃	classification output
1	True	Hot	High	No
2	True	Hot	High	No
3	False	Hot	High	Yes
4	False	Cool	Normal	Yes
5	False	Cool	Normal	Yes
6	true	Cool	High	No
7	true	Hot	High	No
8	true	Hot	Normal	Yes
9	False	Cool	Normal	Yes
10	False	Cool	High	Yes

Solution(a₁)

S

6 yes	
4 no	

$$E(S) = -\left[\frac{6}{10} \log_2 \frac{6}{10} + \frac{4}{10} \log_2 \frac{4}{10}\right] = 0.971$$

S₁ TrueS₂ False

$$E(S_1) = -\left[\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}\right] = 0.7219$$

1 yes	5 yes
4 no	0 no

$$E(S_2) = -\left[\frac{5}{5} \log_2 \frac{5}{5} + 0\right] = 0$$

$$\text{IG}(S, a_1) = 0.971 - \frac{5}{10} * 0.7219 - \frac{5}{10} * 0 = 0.61$$

S

(a₂)

⑩

6 Yes

4 No

Hot

Cool

S₁

2 Yes

⑤

3 No

S₂

4 Yes

⑤

1 No

$$E(S) = 0.971$$

حل a₁ في المراجعة

$$E(S_1) = -\left(\frac{2}{5} \log_2 \frac{2}{5} + \frac{3}{5} \log_2 \frac{3}{5}\right) = 0.971$$

$$E(S_2) = -\left(\frac{4}{5} \log_2 \frac{4}{5} + \frac{1}{5} \log_2 \frac{1}{5}\right) = 0.7219$$

$$IG(S, a_2) = 0.971 - \frac{5}{10} * 0.971 - \frac{5}{10} * 0.7219 = 0.1246$$

(a₃)

⑩

6 Yes

S

4 No

High

Normal

S₁

2 Yes

⑥

4 No

S₂

4 Yes

④

0 No

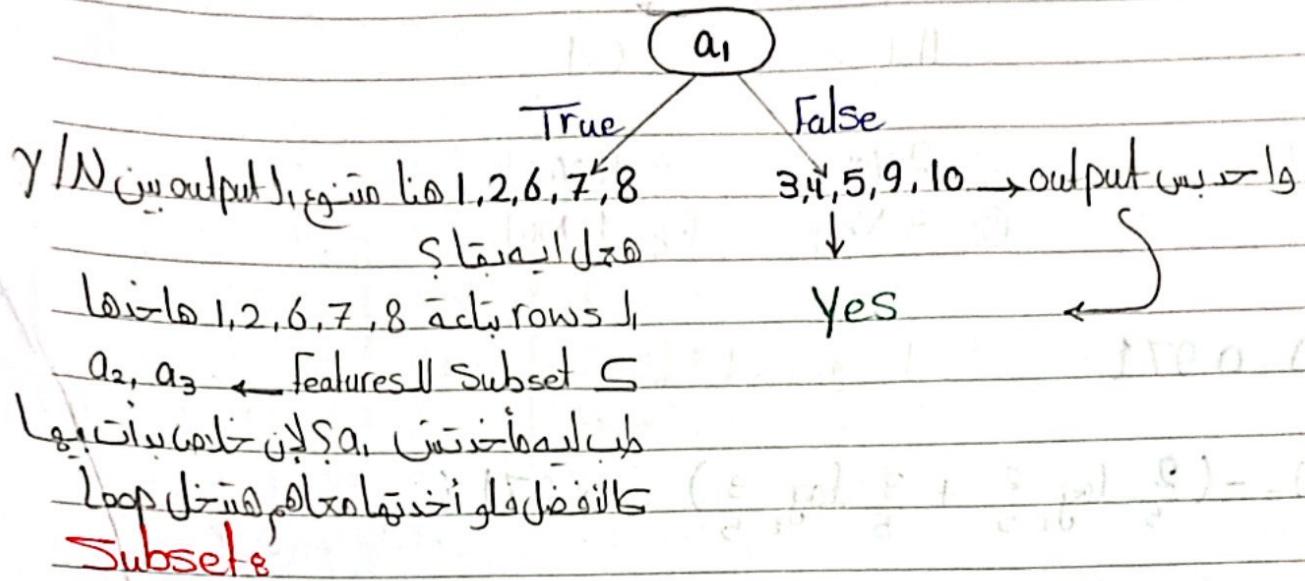
$$E(S) = 0.971$$

$$E(S_1) = -\left(\frac{2}{6} \log_2 \frac{2}{6} + \frac{4}{6} \log_2 \frac{4}{6}\right) = 0.913$$

$$E(S_2) = -\left(\frac{4}{4} \log_2 \frac{4}{4} + 0\right) = 0$$

$$IG(S, a_3) = 0.971 - \frac{6}{10} * 0.913 - \frac{4}{10} * 0 = 0.42$$

a_1 is the best \leftarrow Entropy $IG(S, a_1)$



dataset $S \subseteq$ مجموعها

instance	a_2	a_3	O/P
1	Hot	High	No
2	Hot	High	No
6	Cool	High	No
7	Hot	High	No
8	Hot	Normal	Yes

Solution

(a2)	S	1 Yes	
	⑤	4 No	
		Hot	Cool
	S ₁	1 Yes	S ₂ 0 Yes
	④	3 No	① 1 No

$$E(S) = 0.7219 \leftarrow \text{بالنسبة إلى الجدول}$$

$$E(S_1) = 0.8113$$

$$E(S_2) = 0$$

$$IG(S, a_2) = 0.07286$$

(a₃)

S	1 Yes
5	4 No

High

Normal

S₁

(4)

0 Yes

4 No

S₂

(1)

1 Yes

0 No

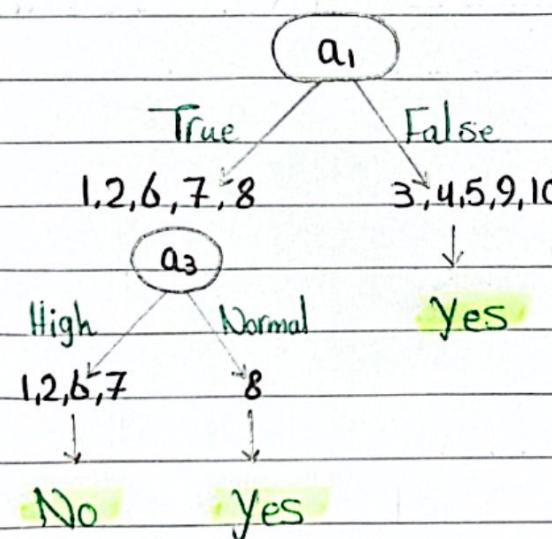
$$E(S) = 0.7219$$

$$E(S_1) = 0$$

$$E(S_2) = 0$$

$$IG(S, a_3) = 0.7219$$

✓ a₁ و a₃ هما الأفضل The best ← Entropy الأعلى ← IG(S, a₃)



* كمطوية لو هناك معايير متساوية بناء على a₃ وملح output بناء على a₃ وهو المعيار احتمال
وتقسمت على طبع output بناء على a₂ ومحبس حاجة واحدة فتحل ايهما
متى لا يتحقق majority بناء على output بناء على a₁

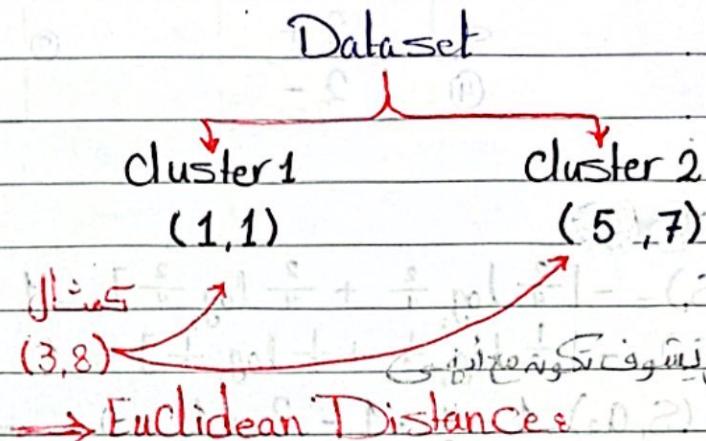
unsupervised learning

Clustering

K-means

Ex 8 K=2, assume initial Centroids $\rightarrow A_1, A_4$

instance	X_1	X_2
A_1	1	-1
A_2	1.5	2
A_3	3	4
A_4	5	7
A_5	3.5	5
A_6	4.5	5
A_7	3.5	4.5



$$D = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

Solution

First iteration $\Rightarrow A_1(1, 1), A_4(5, 7)$

new Centroids \Rightarrow دلوقتي عايز أجيبي

Dataset	Distance	Cluster	new Centroids	second iteration
A_1	1 1 0	C_1	$C_1 = \{A_1, A_2, A_3\}$	
A_2	1.5 2 1.12	C_1	$C_1 = \left(\frac{1+1.5+3}{3}, \frac{1+2+4}{3}\right)$	
A_3	3 4 3.61	C_1	$C_1 = (1.83, 2.33)$	
A_4	5 7 7.21	C_2		
A_5	3.5 5 4.72	C_2	$C_2 = \{A_4, A_5, A_6, A_7\}$	
A_6	4.5 5 5.31	C_2	$C_2 = \left(\frac{5+3.5+4.5+3.5}{4}, \frac{7+5+5+4.5}{4}\right)$	
A_7	3.5 4.5 4.3	C_2	$C_2 = (4.12, 5.38)$	

Second iteration $\Rightarrow C_1(1.83, 2.33), C_2(4.12, 5.38)$

العنوان: Unsupervised Learning
 يعني أننا نعطي data من غير label ببساطة أقسامها
 K-Means ← groups
 ↓
 groups

هو مدين instance كل dataset يكون في شكل زوج مربّع

$$A_1 (x_{A_1}, y_{A_1})$$

$$A_2 (x_{A_2}, y_{A_2})$$

$$\vdots$$

هو يجد كل هذين \leftarrow Clusters من dataset دى
 فهو في المثال ده حدلى \leftarrow
 $C_1: A_1(1,1), C_2: A_4(5,7)$
 فنهتم بالباقي \leftarrow جدول بكل instance عادي زي $A_1, A_2, A_3, A_5, A_6, A_7$
 هعمل \leftarrow جدول لكل Column A₄ و أجيبي المسافة بين
 كل instance مع كل Centroid من اللي محددى

$$D = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

هجيب \leftarrow distance بين A_1 وكل A_4

هجيب \leftarrow distance بين A_1 وكل A_7

بعد ما حست \leftarrow distance هنوفقاً \leftarrow المسافة سن \leftarrow أصغر؟
 C_1 ولا بين A_4 و A_7 \leftarrow $1.12 = A_2, A_1$ سن \leftarrow هكون \leftarrow بع
 وقد حصلنا \leftarrow على \leftarrow distance بناءً على \leftarrow الـ

$$C_1 = \{A_1, A_2, A_3\}, C_2 = \{A_4, A_5, A_6, A_7\} \leftarrow \text{ملحق 1st iteration}$$

\leftarrow x \leftarrow y

لـ \leftarrow يبعاهم \leftarrow new centroids

$$C_1 = \left(\frac{1+1.5+3}{3}, \frac{1+2+4}{3} \right) \quad , \quad C_2 = \left(\frac{5+3.5+4.5+3.5}{4}, \frac{7+5+5+4.5}{4} \right)$$

*Support Vector Machines (SVM)

Classification

Regression.

Notes 8

$$\begin{bmatrix} 2 \\ 3 \end{bmatrix} \cdot \begin{bmatrix} 5 \\ 4 \end{bmatrix} = \begin{bmatrix} 10 \\ 12 \end{bmatrix}$$

ضرب كل رقم في المتأخر له.

dot product

$$\begin{bmatrix} 2 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 4 \end{bmatrix} = \begin{bmatrix} 7 \\ 9 \end{bmatrix}$$

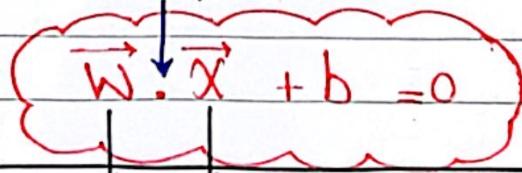
• $2x_1 + 3x_2 + 5 = 0$ Write in vector form

$$\begin{bmatrix} 2 \\ 3 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 5 = 0$$

• $w_1x_1 + w_2x_2 + b = 0$

$$\begin{bmatrix} w_1 \\ w_2 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + b = 0$$

Dot product



$$\vec{w} \cdot \vec{x} + b = 0$$

W vector X vector

Case Study:

Binary Classification $y \in \{+1, -1\}$

↳ 2 Features

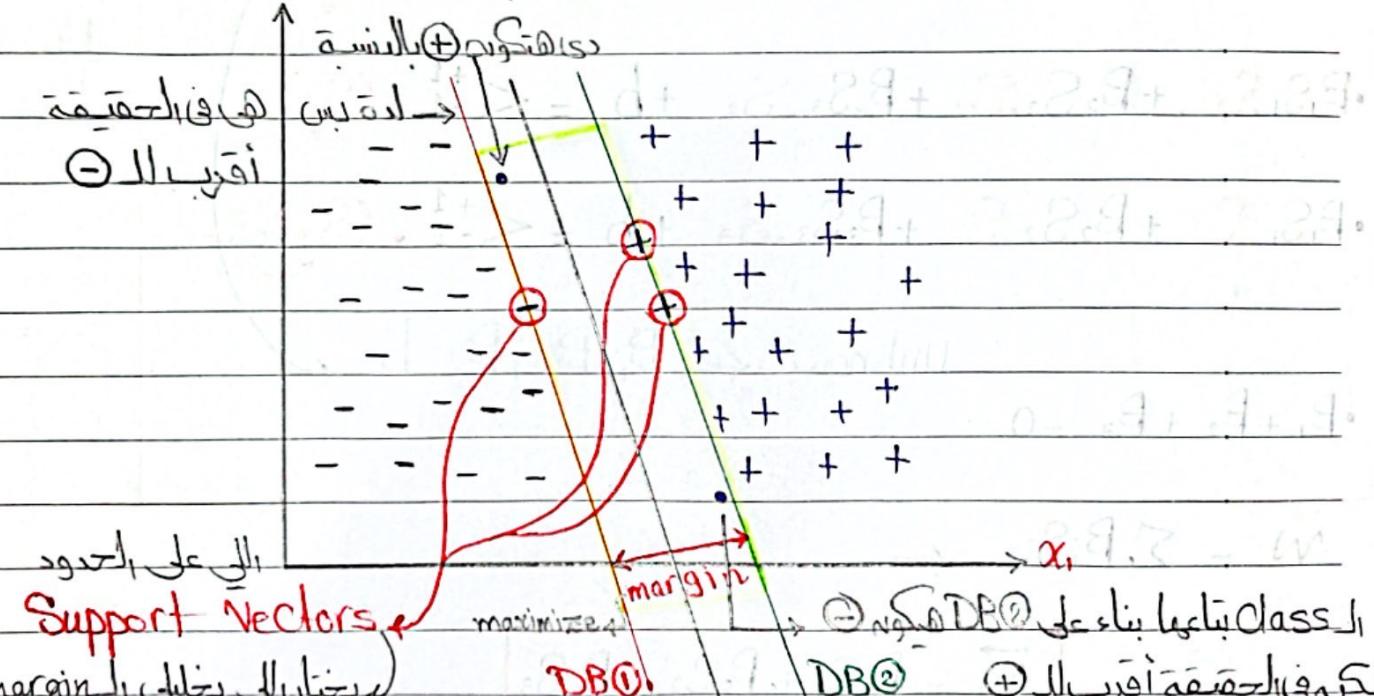
x_1	x_2	y
		+1
		-1
		⋮

فايبرة لـ SVM لأنها تطلق أحسن فصل بين الـ 2 Classes

-1 +1

x_2 طبقان طبقة

في الحقيقة
أقرب الـ -



Support Vectors

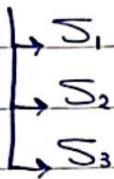
margin
(يختار على يختار)
أكبر مplitude (الهدف)

Best Decision Boundary

(Hyper plane)

$$\vec{w} \cdot \vec{x} + b = 0$$

- Given 3 support vectors $\vec{S}_1, \vec{S}_2, \vec{S}_3$



→ Find the hyper plane equation

Solution

$$\vec{w} \cdot \vec{x} + b = 0$$

? ?

$$\beta_1 S_1 \cdot S_1 + \beta_2 S_2 \cdot S_1 + \beta_3 S_3 \cdot S_1 + b = <^{+1}_{-1} \quad (S_1)$$

$$\beta_1 S_1 \cdot S_2 + \beta_2 S_2 \cdot S_2 + \beta_3 S_3 \cdot S_2 + b = <^{+1}_{-1} \quad (S_2)$$

$$\beta_1 S_1 \cdot S_3 + \beta_2 S_2 \cdot S_3 + \beta_3 S_3 \cdot S_3 + b = <^{+1}_{-1} \quad (S_3)$$

Unknowns $\beta_1, \beta_2, \beta_3, b$

$$\beta_1 + \beta_2 + \beta_3 = 0$$

$$\vec{w} = \sum \beta_i S_i$$

$$\boxed{\vec{w} = \beta_1 S_1 + \beta_2 S_2 + \beta_3 S_3}$$

∴ hyper plane equation is

$$\vec{w} \cdot \vec{x} + b = 0$$

Example: Assume: $S_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$, $S_2 = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \Rightarrow +\text{ve Class}$

$$S_3 = \begin{bmatrix} 4 \\ 0 \end{bmatrix} \Rightarrow -\text{ve Class}$$

Find hyperplane equation.

Solution

$$S_1 \cdot S_1 = \begin{bmatrix} 4 \\ 1 \end{bmatrix} \Rightarrow 4+1=5$$

$$S_1 \cdot S_2 = \begin{bmatrix} 4 \\ -1 \end{bmatrix} \Rightarrow 4-1=3$$

$$S_1 \cdot S_3 = 8+0=8$$

$$S_2 \cdot S_2 = 4+1=5$$

$$S_2 \cdot S_3 = 8+0=8$$

$$S_3 \cdot S_3 = 16+0=16$$

$$5\beta_1 + 3\beta_2 + 8\beta_3 + b = 1$$

$$3\beta_1 + 5\beta_2 + 8\beta_3 + b = 1$$

$$8\beta_1 + 8\beta_2 + 16\beta_3 + b = -1$$

$$\beta_1 = -\beta_2 - \beta_3$$

من رابع معادلة فوق، هنا خدّها ونحوها في 3 معادلات فوق

$$5(-\beta_2 - \beta_3) + 3\beta_2 + 8\beta_3 + b = 1 \Rightarrow -2\beta_2 + 3\beta_3 + b = 1$$

$$3(-\beta_2 - \beta_3) + 5\beta_2 + 8\beta_3 + b = 1 \Rightarrow 2\beta_2 + 5\beta_3 + b = 1$$

$$8(-\beta_2 - \beta_3) + 8\beta_2 + 16\beta_3 + b = -1 \Rightarrow 0\beta_2 + 8\beta_3 + b = -1$$

$$\downarrow \beta_3 = -0.5 / \beta_2 = 0.25 / \beta_1 = -0.25 + 0.5 = 0.25$$

$$b = 3$$

$$\vec{w} = \beta_1 S_1 + \beta_2 S_2 + \beta_3 S_3 = 0.25 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + 0.25 \begin{bmatrix} 2 \\ -1 \end{bmatrix} - 0.5 \begin{bmatrix} 4 \\ 0 \end{bmatrix} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

hyper plane equation $\vec{w} \cdot \vec{x} + b = 0$

$$\begin{bmatrix} -1 \\ 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 3 = 0 \rightarrow -x_1 + 3 = 0$$

$$x_1 - 3 = 0$$

$$x_1 = 3$$

Naive Bayes

Conditional probability, Naive Bayes Algorithm

Day	outlook	Temperature	Humidity	Wind	play Tennis
D ₁	Sunny	Hot	High	Weak	No
D ₂	Sunny	Hot	High	Strong	No
D ₃	Overcast	Hot	High	Weak	Yes
D ₄	Rain	Mild	High	Weak	Yes
D ₅	Rain	Cool	Normal	Weak	Yes
D ₆	Rain	Cool	Normal	Strong	No
D ₇	Overcast	Cool	Normal	Strong	Yes
D ₈	Sunny	Mild	High	Weak	No
D ₉	Sunny	Cool	Normal	Weak	Yes
D ₁₀	Rain	Mild	Normal	Weak	Yes
D ₁₁	Sunny	Mild	Normal	Strong	Yes
D ₁₂	Overcast	Mild	High	Strong	Yes
D ₁₃	Overcast	Hot	Normal	Weak	Yes
D ₁₄	Rain	Mild	High	Strong	No

Test a New instance

outlook = sunny

Temperature = Cool

Humidity = High

wind = Strong

Solution

$$\text{O/p} \xrightarrow{\text{yes}} \text{Yes } (9) \rightarrow P(\text{Yes}) = \frac{9}{14}$$

$$\xrightarrow{\text{No}} \text{No } (5) \rightarrow P(\text{No}) = \frac{5}{14}$$

outlook	Yes	No		Temperture	Yes	No
Sunny	$\frac{2}{9}$	$\frac{3}{5}$		Hot	$\frac{2}{9}$	$\frac{2}{5}$
overCast	$\frac{4}{9}$	$\frac{0}{5}$		Mild	$\frac{4}{9}$	$\frac{2}{5}$
rain	$\frac{3}{9}$	$\frac{2}{5}$		Cool	$\frac{3}{9}$	$\frac{1}{5}$

Humidity	Yes	No		Wind	Yes	No
High	$\frac{3}{9}$	$\frac{4}{5}$		Weak	$\frac{6}{9}$	$\frac{2}{5}$
Normal	$\frac{6}{9}$	$\frac{1}{5}$		Strong	$\frac{3}{9}$	$\frac{3}{5}$

New instance : outlook = sunny

Temperture = Cool

Humidity = High

Wind = Strong

yes(total) yes(sun) yes(Cool) yes(High) yes(strong)

$$P(\text{Yes} | \text{instance}) = \frac{9}{14} * \frac{2}{9} * \frac{3}{9} * \frac{3}{9} * \frac{3}{9} = 0.0053$$

$$P(\text{No} | \text{instance}) = \frac{5}{14} * \frac{3}{5} * \frac{1}{5} * \frac{4}{5} * \frac{3}{5} = 0.0206$$

$$P(\text{No} | \text{instance}) > P(\text{Yes} | \text{instance})$$

Then Classification output is No.